



Projet : *Diagnostic de performance Énergétique (DPE)*
Phase 1 : Study

Data sciences project

Master 1 : Data Sciences for Societal Challenges (DS4SC)

Encadrants :

Mme Veronika Peralta
M. Alexandre Chanson

Réalisé par l'équipe 7 :

Douaa Laib
Meriem Bennama
Siham Mehidi
Arwa Mohamed

Table des matières

1	Contexte	2
2	Problématique	2
3	Profils d'utilisateurs du dashboard	2
3.1	Décideurs publics	3
3.2	Gestionnaires de patrimoine immobilier	3
3.3	Professionnels du secteur privé	3
3.4	Particuliers	4
4	Objectifs	5
4.1	Consommation énergétique (DPE)	5
4.1.1	Justification du choix d'axe	5
4.1.2	Les besoins détaillées	5
4.2	Émissions de gaz à effet de serre (GES) :	6
4.2.1	Justification du choix d'axe	6
4.2.2	Les besoins détaillées	6
4.3	Analyse socio-économique et contextuelle	7
4.3.1	Justification du choix d'axe	7
4.3.2	Les besoins détaillées	7
4.4	Recommandations et prédictions de performance	8
4.4.1	Justification du choix d'axe	8
4.4.2	Les besoins détaillées	8
5	Présentation des jeux de données	9
5.1	Base de données ADEME DPE	10
5.1.1	Méthodes de calcul	10
5.1.2	Structure des bases de données DPE	11
5.1.3	Sélection des échantillons et variables issues du DPE	14
5.2	Base de données INSEE	15
6	Gestion du projet	17
6.1	Plan de travail et répartition des tâches	17
6.2	Moyens de communication	18

1. Contexte

Le Diagnostic de Performance Énergétique DPE constitue un outil réglementaire central de la politique de transition énergétique en France. Il a pour objectif d'évaluer la performance des bâtiments en mesurant leur consommation énergétique exprimée en (kW-hEP/m².an) et leurs émissions de gaz à effet de serre GES exprimées en (kgCO₂/m².an). Ces indicateurs se traduisent par un classement normé (étiquettes A à G), devenu indispensable dans le cadre des transactions immobilières et de l'éligibilité à certaines aides à la rénovation.

Dans le contexte des engagements nationaux et européens en matière de réduction de l'empreinte carbone et d'amélioration de l'efficacité énergétique du parc immobilier, le DPE occupe une place stratégique en tant qu'outil de pilotage, de suivi et d'aide à la décision. Afin de renforcer sa portée, l'ADEME a mis en place depuis 2020 une base de données en open data, regroupant plusieurs millions de diagnostics couvrant l'ensemble du territoire et l'ensemble des typologies de bâtiments (maisons individuelles, logements collectifs, bâtiments tertiaires, centres commerciaux).

Cette base de données, d'une grande richesse mais également volumineuse et hétérogène, représente un levier majeur pour analyser, comparer et projeter la performance énergétique du parc immobilier français. Il convient toutefois de distinguer les diagnostics réalisés avant et après juillet 2021, date à laquelle une nouvelle méthodologie de calcul a été introduite, ce qui conditionne les étapes de nettoyage, d'harmonisation et de fusion des données.

2. Problématique

La base DPE open data de l'ADEME ne se limite pas aux seuls indicateurs réglementaires. Elle intègre également des informations détaillées sur les caractéristiques des bâtiments (surface, année de construction, isolation, systèmes de chauffage, ventilation, etc.), leurs consommations par usage (chauffage, eau chaude sanitaire, refroidissement, éclairage, etc.), les factures énergétiques historiques, ainsi que des recommandations de travaux assorties d'estimations de coûts, d'économies potentielles et de retours sur investissement. Cependant, l'exploitation directe de cette ressource soulève plusieurs difficultés majeures :

- un volume massif de données.
- une structuration complexe (multiplicité de tables et de références croisées).
- une forte hétérogénéité selon les méthodes de calcul.
- l'absence d'outils de synthèse, de visualisation et d'aide à la décision adaptés.

Dès lors, il devient indispensable de concevoir une solution interactive, visuelle et prédictive, capable de transformer cette masse de données hétérogènes en indicateurs clairs, comparables et actionnables, exploitables à différentes échelles d'analyse par les acteurs publics, privés et particuliers.

3. Profils d'utilisateurs du dashboard

La plateforme visée s'adresse à un panel diversifié d'acteurs publics et privés, chacun disposant de besoins et de niveaux d'expertise distincts. L'identification de ces profils est

essentielle pour définir les fonctionnalités prioritaires et adapter l’ergonomie du dashboard.

3.1 Décideurs publics

Les décideurs publics regroupent principalement les collectivités locales, les administrations et les agences régionales de l’énergie. Ces acteurs pilotent la transition énergétique sur leur territoire et suivent l’impact des politiques publiques. Ils nécessitent une vision globale et multi-échelle des performances énergétiques du parc immobilier.

- **Besoins :** Vision globale du parc immobilier, identification des zones prioritaires, suivi de l’impact des politiques publiques.
- **Visualisations :**
 - Cartes interactives multi-échelles (commune, département, région) avec heat-maps de consommation énergétique et émissions de GES.
 - Graphiques de tendances temporelles pour suivre l’évolution des performances avant/après interventions ou réformes.
- **Fonctionnalités :**
 - Filtrage par type de bâtiment, période de construction ou classe énergétique.
 - Export de rapports synthétiques et KPI pour décision et communication.

3.2 Gestionnaires de patrimoine immobilier

Les gestionnaires de patrimoine immobilier incluent les bailleurs sociaux, les foncières et les syndicats de copropriété. Ils doivent assurer le suivi de leur parc, identifier les bâtiments énergivores et prioriser les investissements en rénovation.

- **Besoins :** Suivi du parc, détection des bâtiments énergivores, priorisation des travaux de rénovation.
- **Visualisations :**
 - Tableaux de bord par bâtiment ou ensemble de bâtiments avec consommation énergétique, classe DPE, émissions GES.
 - Alertes visuelles pour bâtiments « passoires thermiques » ou dépassant certains seuils.
- **Fonctionnalités :**
 - Filtrage et recherche par adresse, type de bâtiment ou classe énergétique.
 - Calcul des économies potentielles et du temps de retour sur investissement pour des scénarios de rénovation.

3.3 Professionnels du secteur privé

Les professionnels du secteur privé regroupent notamment les agences immobilières, les énergéticiens, les bureaux d’études et les entreprises du bâtiment. Ils utilisent les données pour évaluer et valoriser les biens, mais aussi pour concevoir et proposer des solutions techniques adaptées.

- **Besoins :** Évaluer les performances énergétiques, valoriser les biens, proposer des solutions techniques adaptées.

- **Visualisations :**
 - Cartes interactives et tableaux de bord détaillés par type de bâtiment ou système énergétique.
 - Graphiques comparatifs des consommations et émissions selon les systèmes de chauffage, ventilation ou isolation.
- **Fonctionnalités :**
 - Accès à des recommandations techniques personnalisées selon les caractéristiques des bâtiments.
 - Simulation d'améliorations et estimation de coûts/économies pour valorisation immobilière.

3.4 Particuliers

Les particuliers comprennent aussi bien les propriétaires que les locataires. Ils cherchent avant tout à comprendre la performance énergétique de leur logement, à estimer l'impact financier de leur consommation et à évaluer les bénéfices potentiels de travaux de rénovation.

- **Besoins :** Comprendre la performance énergétique de leur logement, estimer l'impact financier et environnemental de travaux.
- **Visualisations :**
 - Indicateurs simples et visuels (étiquettes A–G, jauges d'émissions GES).
 - Comparaison avec logements similaires dans le quartier ou la commune.
- **Fonctionnalités :**
 - Simulateur interactif pour tester différentes options de rénovation et voir leurs effets sur consommation et coûts.
 - Téléchargement de rapports simplifiés à usage personnel ou pour aides financières.

Profil utilisateur	Visualisations attendues	Fonctionnalités clés
Décideurs publics	Cartes interactives (heatmaps par commune/département), graphiques temporels, indicateurs globaux	Identifier zones prioritaires, suivre impact des politiques énergétiques, filtrer par typologie et période
Gestionnaires de patrimoine	Tableaux de bord par bâtiment, graphiques comparatifs, alertes sur seuils de consommation DPE/GES	Suivi parc immobilier, détecter bâtiments énergivores, calculer économies et ROI des travaux
Professionnels privés	Graphiques détaillés par typologie et système, histogrammes comparatifs, filtres interactifs	Évaluer performance énergétique, proposer solutions techniques, générer rapports
Particuliers	Jauges ou thermomètres DPE/GES, comparaison avec moyenne du quartier, visualisations simples A–G	Comprendre performance énergétique, estimer coût et impact environnemental des travaux

TABLE 1 – Résumé des profils utilisateurs, visualisations et fonctionnalités clés du dashboard

4. Objectifs

Le projet a pour ambition de concevoir un dashboard interactif avancé permettant l’analyse multi-échelles des DPE, structuré autour de quatre axes stratégiques :

4.1 Consommation énergétique (DPE)

4.1.1 Justification du choix d’axe

La consommation énergétique constitue un indicateur fondamental du DPE. Elle reflète directement :

- la qualité de l’enveloppe thermique du bâtiment.
- la performance de ses systèmes énergétiques (chauffage, eau chaude sanitaire, ventilation, climatisation).
- et les usages associés.

Son analyse permet d’aller au-delà du simple constat réglementaire en développant des outils explicatifs (identifier les facteurs qui influencent la consommation), prédictifs (anticiper la performance énergétique de bâtiments non encore diagnostiqués) et d’aide à la décision (orienter les politiques publiques, prioriser les investissements et guider les ménages dans leurs choix de rénovation).

4.1.2 Les besoins détaillées

1. Analyse des facteurs de consommation :

Identifier les déterminants techniques qui influencent le plus la consommation énergétique.

Objectif : quantifier l’effet de chaque facteur (ex. une maison construite avant 1975 consomme en moyenne +45 kWhEP/m².an par rapport à une maison post-2000).

Méthodes : analyses multivariées (régressions multiples, arbres de décision interprétables, SHAP values).

2. Prédiction des DPEs :

Développer des modèles supervisés permettant de prédire la consommation énergétique (kWhEP/m².an) et la classe énergie (A–G) à partir des caractéristiques du logement.

Objectifs : anticiper la performance énergétique des logements non encore diagnostiqués, détecter les “passoires thermiques” et simuler l’effet de modifications des caractéristiques.

Méthodes : Random Forest, Gradient Boosting, XGBoost ou régressions.

3. Cartographie interactive multi-échelles enrichie :

Mettre en place une visualisation cartographique permettant non seulement de représenter la consommation moyenne et la répartition des classes énergétiques (A–G)

à différentes échelles (commune, département, région), mais aussi de combiner cette dimension géographique avec d'autres facteurs clés (les facteurs identifiés dans l'Analyse des facteurs de consommation). Parmi ceux-ci :

- la typologie des bâtiments (maisons individuelles, appartements, bâtiments tertiaires, etc.),
- l'année de construction ou la période réglementaire,
- les systèmes énergétiques utilisés (chauffage, eau chaude, ventilation).

Objectifs : identifier les zones géographiques prioritaires, comparer les performances inter-territoires et croiser la dimension spatiale avec les facteurs de consommation.

4.2 Émissions de gaz à effet de serre (GES) :

4.2.1 Justification du choix d'axe

Les émissions de GES constituent un indicateur clé de l'impact environnemental des bâtiments. Analyser ces émissions permet de :

- Quantifier l'empreinte carbone des logements et identifier les zones ou typologies de bâtiments les plus émissives.
- Prioriser les politiques de réduction des émissions, comme les rénovations ciblées ou le remplacement de systèmes énergétiques.
- Compléter l'évaluation énergétique en allant au-delà de la simple consommation, et relier performance énergétique et impact environnemental.

4.2.2 Les besoins détaillées

1. Analyse descriptive des classes GES

Objectif : visualiser la répartition des logements par classe GES (A à G), moyenne des émissions en kgCO₂/m².an, et identifier les zones à forte émission.

Méthodes : statistiques descriptives, visualisations cartographiques et graphiques comparatifs.

2. Clustering des logements selon leur profil d'émissions :

Objectifs : regrouper les logements avec des profils d'émission similaires pour dégager des typologies (ex. "passoires thermiques", logements anciens chauffés au fioul).

Méthodes : clustering non supervisé (K-means, DBSCAN, hierarchical clustering).

3. Prédiction des émissions de CO₂ :

Objectifs : développer un modèle supervisé pour estimer la valeur exacte des émissions d'un logement en kgCO₂/m².an à partir de ses caractéristiques.

Méthodes : régression (Random Forest, Gradient Boosting, XGBoost, régression linéaire).

4. Classification des logements par classe GES :

Objectifs : prédire la classe GES (A–G) d’un logement pour identifier rapidement les bâtiments à forte empreinte carbone.

Méthodes : classification supervisée (Random Forest, XGBoost, SVM).

4.3 Analyse socio-économique et contextuelle

4.3.1 Justification du choix d’axe

L’analyse socio-économique permet de comprendre comment les performances énergétiques des bâtiments s’inscrivent dans un contexte humain et territorial. Elle relie les DPE à des facteurs comme le revenu, la densité urbaine, l’ancienneté des logements, le type de ménage ou la précarité énergétique. Cette dimension est essentielle pour :

- Identifier les populations ou zones les plus vulnérables aux consommations énergétiques élevées.
- Prioriser les interventions et politiques publiques (subventions, aides ciblées).
- Compléter l’analyse purement technique par un volet humain et contextuel.

4.3.2 Les besoins détaillées

1. Cartographie socio-économique des logements énergivores

Objectif : visualiser la répartition géographique des logements à forte consommation ou à haute émission de GES selon les revenus et la précarité énergétique.

Méthodes : analyses descriptives, croisement statistique, cartographie interactive multi-échelles.

2. Étude des liens entre caractéristiques des logements et facteurs socio-économiques :

Objectifs : identifier si certains types de bâtiments (anciens, mal isolés, chauffés au fioul) sont concentrés dans des zones à faibles revenus ou populations fragiles.

Méthodes : corrélations, régressions multiples, analyse de variance, clustering selon profils socio-énergétiques.

3. Segmentation socio-énergétique des territoires :

Objectifs : regrouper les communes ou quartiers selon leur profil combiné consommation/GES et socio-économie, pour orienter les politiques publiques.

Méthodes : clustering non supervisé (K-means, DBSCAN), analyse factorielle.

4.4 Recommandations et prédictions de performance

4.4.1 Justification du choix d'axe

Les DPE contiennent souvent plus que de simples notes (A à G) : ils proposent aussi des recommandations concrètes (isoler les murs, changer de chauffage...), parfois avec des indices qualitatifs comme le coût estimé, le gain attendu ou l'horizon de retour. Ces informations sont précieuses mais rarement exploitées à grande échelle. Les mettre au cœur de notre analyse permet d'aller au-delà du constat : on peut prioriser, comparer, simuler, et surtout aider à décider. Ce volet donne donc une dimension opérationnelle et utile à notre projet.

4.4.2 Les besoins détaillés

1. Analyse et prédiction des recommandations de travaux à partir des DPE

Objectif : Attribuer à chaque logement une ou plusieurs recommandations de travaux. Deux cas :

1. si des recommandations existent dans le DPE (commentaires), les identifier et standardiser ;
2. si elles sont absentes, prédire les recommandations probables en fonction du profil du logement.

Restituer les résultats par zones (commune, département) et typologies.

Méthodes :

- Extraire les commentaires de recommandations, normaliser les libellés et les regrouper en familles de travaux (isolation, chauffage, ventilation, menuiseries...).
- Pour les logements sans commentaire, entraîner un modèle de classification supervisée (potentiellement multi-étiquette) qui prédit les travaux les plus pertinents à partir des attributs du logement.
- Cartographier la fréquence des familles de travaux par territoire.

Scénario d'usage : Un parc de 100 000 DPE est analysé. Pour un logement dont le DPE est muet, l'outil propose "isolation des combles" et "amélioration de la ventilation", car ces recommandations sont fréquentes pour des logements similaires (même ancienneté, surface, système de chauffage). Sur la carte, l'utilisateur visualise les travaux dominants par commune et peut cibler les zones prioritaires.

Utilité :

- Donner des conseils personnalisés même lorsque le DPE ne renseigne pas les travaux.
- Aider collectivités et bailleurs à prioriser les actions (zones où isolation/chauffage est le plus recommandé).
- Préparer la phase de simulation (besoin 2) avec des recommandations structurées

et prédictibles.

2. Simulation de scénarios “après travaux” optimisation (avec ROI) :

Un module interactif doit permettre de simuler et comparer automatiquement différentes combinaisons de recommandations (ex. isolation des murs + remplacement de chaudière + double vitrage) pour un logement individuel ou un portefeuille de bâtiments. Pour chaque scénario, le système doit estimer :

- la consommation énergétique post-travaux (kWhEP/m².an),
- la nouvelle classe DPE (A–G),
- la réduction des émissions de GES (kgCO₂/m².an),
- les économies annuelles attendues (€),
- le coût total des travaux,
- le temps de retour sur investissement (ROI).

L’outil devra proposer plusieurs scénarios types :

- **Minimal** : travaux ciblés à faible coût,
- **Optimal** : combinaison offrant le meilleur équilibre efficacité énergétique / coût,
- **Global** : rénovation complète maximisant la performance énergétique.

Méthode :

- Réutiliser le modèle prédictif DPE existant (appris dans l’axe 1 du projet).
- “Transformer” les caractéristiques du logement selon les travaux sélectionnés (ex. isolation-murs=oui, chauffage=PAC) puis prédire l’état “après travaux”.
- Calculer le coût (barèmes paramétrables), les économies et le ROI, comparer les scénarios et recommander la meilleure combinaison pour l’objectif donné.

Scénario d’usage : Logement classe E, 270 kWh/m².an. L’utilisateur coche “isolation des combles” + “pompe à chaleur”. L’outil affiche : classe C projetée (150 kWh/m².an), GES ÷2, coût total et ROI estimé. Variante : “Atteindre la classe C avec <= 20 000 €” → l’outil propose automatiquement le bouquet optimal au meilleur ratio gain/coût.

Utilité : Cette fonctionnalité aide les particuliers à se projeter grâce à des vues avant/après et à hiérarchiser les travaux, offre aux gestionnaires et aux collectivités un levier de planification via des scénarios budgétés et des estimations d’impact énergie/CO₂, et produit des indicateurs décisionnels harmonisés, comparables entre logements et territoires.

5. Présentation des jeux de données

Dans le cadre de ce projet, quatre axes d’analyse ont été définis :

- Consommation énergétique (DPE),
- Émissions de gaz à effet de serre (GES),

- Analyse socio-économique et contextuelle,
- Recommandations et prédictions de performance énergétique.

Pour répondre à ces objectifs, l'ensemble de la base ADEME DPE constitue la matière première centrale pour les trois axes liés à la performance énergétique et environnementale, tandis que des bases complémentaires (INSEE, données territoriales, socio-économiques) viendront enrichir l'axe d'analyse contextuelle.

5.1 Base de données ADEME DPE

L'ADEME met à disposition en open data des millions de diagnostics de performance énergétique réalisés sur l'ensemble du territoire français. Ces données, essentielles pour analyser et prédire la performance énergétique des bâtiments, se déclinent en deux grandes périodes en fonction de la méthode de calcul réglementaire utilisée, comme l'illustre la figure 1.




FIGURE 1 – Répartition des méthodes de calcul du DPE

5.1.1 Méthodes de calcul

Méthode 3CL 2006 Avant 2021, les diagnostics de performance énergétique étaient établis selon la méthode 3CL 2006 (Calcul de la Consommation Conventiennelle des Logements), utilisant deux approches possibles :

- **Approche conventionnelle** : basée sur les caractéristiques physiques du logement (surface, isolation, année de construction, systèmes de chauffage et d'eau chaude sanitaire, ventilation),

- **Approche sur factures** : fondée sur les factures énergétiques réelles des trois dernières années.

Cette double approche entraînait une forte hétérogénéité des résultats et réduisait leur comparabilité.

Méthode 3CL 2021 Depuis juillet 2021, une version révisée et fiabilisée du calcul conventionnel, harmonisée avec la réglementation environnementale RE2020, est appliquée. Elle repose uniquement sur une approche conventionnelle prenant en compte :

- les caractéristiques détaillées de l’enveloppe (murs, planchers, toiture, vitrages, ponts thermiques),
- les systèmes énergétiques (chauffage, ECS, ventilation, climatisation, énergies renouvelables),
- les apports internes (occupants, équipements) et solaires (orientation, exposition),
- la zone climatique et l’altitude,
- un indicateur spécifique de confort d’été.

Cette méthode garantit une évaluation plus fiable, homogène et comparable des logements sur l’ensemble du territoire.

5.1.2 Structure des bases de données DPE

DPE avant 2021

- **Structure** : organisée en tables relationnelles thématiques.
- **Méthode de calcul** : Méthode 3CL 2006.

Table	Nb attributs	Description
TD001	73	Table principale : métadonnées du DPE (identifiants, dates, méthode, logiciel, consommations, classes énergie/GES, surfaces, localisation, géocodage).
TD002	7	Consommations d’énergie : énergie finale et primaire, frais annuels, détaillés par usage (chauffage, ECS, refroidissement, éclairage, auxiliaires).
TD003	4	Descriptifs du DPE : textes descriptifs libres, type de descriptif, indicateurs d’effacement.
TD004	8	Améliorations proposées : mesures de rénovation, effort d’investissement, économies, retour sur investissement, crédit d’impôt, commentaires.
TD005	4	Fiche technique : valeurs saisies pour les différents paramètres techniques (parois, systèmes, ventilation).
TD006	11	Informations bâtiment : besoins de chauffage, inertie, altitude, nombre de niveaux, nombre d’appartements, surfaces thermiques.
TD007	13	Parois opaques : murs, planchers, toitures, caractéristiques thermiques (U, surfaces, isolation).

Table	Nb attributs	Description
TD008	14	Baies vitrées : fenêtres, surfaces vitrées, orientation, type de vitrage, protections solaires, masques proches.
TD009	2	Masques solaires lointains : obstacles externes réduisant l'ensoleillement.
TD010	5	Ponts thermiques : longueurs, coefficients de transmission, type, localisation et déperditions associées.
TD011	7	Installations de chauffage : type d'installation, configuration, énergie, surface chauffée, intermittence.
TD012	29	Générateurs de chauffage : type, énergie, rendements (émission, distribution, génération), puissance, consommation, couverture solaire.
TD013	8	Installations d'ECS (eau chaude sanitaire) : besoins ECS, surfaces desservies, type et configuration d'installation.
TD014	25	Générateurs ECS : type, énergie, rendement, stockage, pertes, volume, facteurs solaires, dates d'installation.
TD015	11	Production d'énergie renouvelable : photovoltaïque, cogénération, micro-éolien, surface de capteurs, production estimée.
TD016	25	Factures : consommations et coûts réels (années N, N-1, N-2), unités, type d'énergie, répartition charges.
TD017	10	Consommations conventionnelles pour bâtiments neufs : énergie finale et primaire, frais annuels par usage.

TABLE 2: Résumé des tables DPE avant 2021 (TD001–TD017)

DPE après 2021

- **Structure** : organisée en tables relationnelles thématiques, avec des données détaillées et standardisées.
- **Méthode de calcul** : Méthode 3CL 2021.

Table	Nb attributs	Description
Administratif	16	Métadonnées du DPE : identifiants, dates clés, modèle, méthode utilisée, infos copropriété, RPLS, etc.
Bilan DPE	8	Résultats synthétiques : consommations, émissions de GES et étiquettes énergie/GES attribuées.

Table	Nb attributs	Description
Caractéristiques bâtiment	19	Informations structurelles : type, année/période de construction, surfaces, inertie, typologie, usage tertiaire.
Localisation du bien	23	Données géographiques et adresse (BAN, brut, coordonnées, codes INSEE/postaux, géocodage).
Confort d'été	6	Indicateurs de confort thermique en période estivale : inertie, protection solaire, ventilation naturelle.
Dépêrditions	8	Estimation des pertes thermiques par enveloppe, murs, planchers, baies vitrées, ponts thermiques, air.
Isolation	8	Qualité de l'isolation selon les éléments (murs, planchers, combles, toitures, menuiseries) et coefficient Ubat.
Apports et besoins	11	Besoins énergétiques (chauffage, ECS, refroidissement) et apports (internes, solaires) par saison.
Consommation énergie primaire	10	Consommations annuelles en énergie primaire (chauffage, ECS, éclairage, clim, auxiliaires, dépensier).
Consommation énergie finale	10	Consommations annuelles en énergie finale (mêmes usages que primaire) + déclinaisons dépensières.
Consommation par énergie	4	Consommations ventilées par type d'énergie (finale, usage associé, frais annuels).
Coûts	11	Dépenses annuelles en euros : chauffage, ECS, climatisation, éclairage, auxiliaires, scénarios dépensiers.
ECS (Eau Chaude Sanitaire)	13	Données détaillées sur les installations ECS : besoins, générateurs, solaire, stockage, logements desservis.
Chauffage	8 (extensible)	Description des installations de chauffage et générateurs associés (énergie, configuration, usages).
Climatisation	8	Données sur les systèmes de climatisation : générateur, énergie, surface, consommations, scénarios.
Ventilation	3	Type de ventilation, surface ventilée, et indication d'une mise en service postérieure à 2012.
Émissions de GES	13	Émissions de gaz à effet de serre par usage (chauffage, ECS, clim, éclairage, auxiliaires) et scénarios.

Table	Nb attributs	Description
Énergies renouvelables	9	Présence et caractéristiques des systèmes ENR : photovoltaïque, capteurs, production, autoconsommation.

TABLE 3: Résumé des tables DPE après 2021

5.1.3 Sélection des échantillons et variables issues du DPE

Sélection des départements pour l'échantillon avant 2021 : la base de données pré-2021 est structurée à l'échelle départementale, ce qui génère une volumétrie particulièrement importante à traiter. Afin de constituer un échantillon représentatif tout en maîtrisant ce volume, deux départements ont été retenus dans chacune des trois régions choisies. Le critère principal est la diversité des contextes (urbain vs rural, littoral vs intérieur, ancien vs récent), afin de couvrir différentes typologies de bâtiments et situations énergétiques.

— **Région Centre-Val de Loire**

- Indre-et-Loire (37) : département marqué par une agglomération urbaine importante (Tours) et une forte densité de logements collectifs.
- Loir-et-Cher (41) : territoire plus rural avec une prépondérance de maisons individuelles.

— **Région Bretagne**

- Ille-et-Vilaine (35) : département dynamique avec Rennes comme métropole, représentatif des zones urbaines récentes.
- Finistère (29) : territoire littoral et rural, avec un parc plus ancien exposé aux contraintes climatiques atlantiques.

— **Région Corse**

- Haute-Corse (2B) : région montagneuse, marquée par un habitat dispersé et des conditions climatiques spécifiques.
- Corse-du-Sud (2A) : littoral touristique et parc immobilier mixte (résidences principales et secondaires).

Harmonisation des schémas pré-2021 et post-2021 nous avons comparé les schémas pré-2021 et post-2021 et identifié les zones d'intersection (mêmes informations, parfois avec des noms différents ou des agrégations à faire). Pour garantir des analyses cohérentes sur toute la période, nous nous concentrons uniquement sur ces tables/colonnes communes pour faire le choix des colonnes à considérer par la suite. Les colonnes nécessitant un recalcul côté pré-2021 (ex. kWhEP/m² et kgCO₂/m²) seront produites par agrégation et application de facteurs standard par la suite.

Résultats de la comparaison

- Nombre total de tables communes : **14**
- Nombre total de colonnes (intersection) : **89**

TABLE 4 – Tables et colonnes communes identifiées

Table	Nombre de colonnes
Administratif	7
Bilan DPE	2
Caractéristiques bâtiment	7
Localisation	11
Déperditions	2
Besoins	3
Consommation énergie	1
Émissions GES	1
Chauffage	18
ECS	24
Ventilation	1
Énergies renouvelables	6
Coûts	5
Recommandations	1

Exemple de colonne pertinente

Afin d'illustrer notre démarche, nous présentons ci-dessous un exemple de colonne que nous pourrions sélectionner parmi l'intersection. L'idée est de choisir nos variables de manière stratégique, pour couvrir efficacement les besoins du projet sans complexifier inutilement le modèle.

Colonne : `annee_construction`

Besoin associé : Consommation énergétique (analyse descriptive)

Pourquoi c'est clé : l'année de construction est disponible avant et après 2021, et constitue un des facteurs explicatifs majeurs des performances énergétiques. Elle peut être utilisée immédiatement dans des analyses exploratoires (ex. comparer les consommations moyennes ou les étiquettes DPE selon les décennies de construction).

Impact métier : dès un tableau de bord, cette variable permet de mettre en évidence que les bâtiments construits avant 1975 (avant la première réglementation thermique) consomment en moyenne beaucoup plus que ceux construits après 2000. C'est une analyse intuitive, utile pour visualiser des tendances et comprendre les enjeux de rénovation, sans passer par un modèle prédictif.

5.2 Base de données INSEE

Pour l'analyse socio-économique et contextuelle, les données mobilisées sont issues de l'INSEE¹ et seront combinées avec les données du DPE afin de visualiser la répartition géographique des logements à forte consommation ou à haute émission de GES selon les revenus et la précarité énergétique. Le tableau 5 ci-dessous récapitule les jeux de données utilisés ainsi que leurs principales caractéristiques et finalités dans le cadre de l'étude.

1. <https://www.insee.fr/fr/statistiques>

Titre	Sous-titre	Nb col.	Description	Période	Besoins / Analyse
Niveau de vie médian et taux de pauvreté	Revenus localisés sociaux et fiscaux (Filo-sofi)	5	Niveau de vie médian, taux de pauvreté à 60%, décliné par ménage et territoire	2021	Cartographie socio-énergétique, identification des populations vulnérables
Logements	Recensement de la population - Exploitation principale	12	Nombre de logements par catégorie, résidences principales, statut d'occupation, ancienneté d'emménagement	2011–2022	Étude logement / facteurs socio-éco, analyse précarité énergétique
Logements	Recensement de la population - Exploitation complémentaire	6	État d'occupation des résidences principales (norme, sur-occupé, sous-occupé)	2011–2022	Analyse de la sur-occupation et de la densité des ménages vulnérables
Salaires secteur privé (sexe / PCS)	Base Tous salariés (BTS)	6	Salaires nets mensuels ETP, ventilés par sexe et catégorie socioprofessionnelle	2022–2023	Identification zones à faibles revenus ou inégalités salariales
Salaires secteur privé (sexe / âge)	Base Tous salariés (BTS)	6	Salaires nets mensuels ETP, ventilés par sexe et âge	2022–2023	Analyse vulnérabilités selon âge et revenu
Privations matérielles et sociales	Enquête SRCV	11	Indicateurs de privation matérielle et sociale (incapacité de couvrir 5 dépenses courantes sur 13), déclinés par âge, sexe, PCS, emploi, santé	2020–2024	Identifier populations à risque de précarité énergétique et corrélation logement
Population	Recensement - Exploitation complémentaire	6	Population détaillée par sexe, âge (3 tranches), PCS	2011–2022	Étude des caractéristiques sociodémographiques des habitants
Ménages et couples	Recensement - Exploitation principale	9	Population et ménages >=15 ans selon âge, vie en couple, personnes seules, statut conjugal	2011–2022	Analyse des types de ménages et corrélation avec consommation énergétique
Estimations de population	Estimations démographiques	5	Population au 1er janvier selon sexe et âge, âge moyen et médian, part des >=65 ans	1990–2025	Cartographie des zones à forte densité ou population âgée

6. Gestion du projet

Sans organisation ni méthode, la mise en œuvre d'un projet est très difficile. D'où la nécessité d'établir un planning de travail détaillé et clair, afin d'avoir une vue d'ensemble sur l'état d'avancement du projet, de veiller à ce que les tâches soient équitablement réparties et de s'assurer que le projet soit terminé dans les délais prévus.

Cette première phase avait pour objectif de cadrer le projet, de s'approprier les données disponibles (DPE et sources complémentaires) et de définir une charge de travail précise. Elle devait aboutir à un cahier des charges structuré, servant de base aux étapes suivantes de modélisation et d'implémentation.

6.1 Plan de travail et répartition des tâches

L'organisation du travail a reposé sur une articulation entre des activités menées collectivement et une répartition ciblée des responsabilités par axe d'analyse. Dans un premier temps, l'ensemble de l'équipe a travaillé en commun pour explorer les données, définir les axes et clarifier les besoins, ce qui a permis de garantir une vision partagée et une compréhension homogène du projet. Dans un second temps, un découpage par thématiques (consommation énergétique, émissions de GES, recommandations, socio-économie) a été mis en place, afin de permettre à chacun de se spécialiser tout en contribuant à l'objectif global.

Cette répartition progressive a présenté un double avantage : d'une part, elle a favorisé la montée en compétence collective grâce aux tâches initiales partagées ; d'autre part, elle a renforcé l'efficacité du groupe en exploitant les complémentarités et les expertises individuelles. Le fait d'avancer en parallèle sur certaines activités (exploration, extraction, recherche de données complémentaires) a permis d'accélérer le travail et de réduire le risque de blocage. Enfin, un jalon fixé au 15/09 a assuré une consolidation collective (sujet, données, besoins, plan de charge), offrant ainsi une base solide pour aborder la phase suivante de modélisation. La planification de cette phase est représentée par le diagramme de Gantt (figure 2), tandis que le détail des responsabilités et des échéances est synthétisé dans le tableau 6.




FIGURE 2 – Diagramme de Gantt de la phase 1 : Study

Période	Tâches principales	Responsables
02–03/09	Choix du sujet (comparaison des pistes, validation du thème DPE)	Équipe complète
04–09/09	Exploration des données ADEME, recherche de sources complémentaires (INSEE), premières analyses	Travail en groupe
10/09	Consolidation et validation des axes d’analyse, clarification des besoins	Équipe complète
10–12/09	Spécification de la charge (découpage, estimation des efforts, dépendances)	Groupe + encadrant
10–15/09	Approfondissement par axe (consommation, GES, recommandations, socio-économie)	Répartition individuelle
13–15/09	Rédaction du cahier des charges v1 (périmètre, indicateurs, plan de charge)	Équipe complète

TABLE 6 – Répartition des tâches et responsabilités durant la phase 1 (Study)

6.2 Moyens de communication

Il est bien évident qu’une bonne stratégie de communication assure l’efficacité des échanges au sein de l’équipe. De notre part, nous avons utilisé tous les moyens disponibles pour le garantir.

Commençant par les outils de communication classiques — le téléphone et l’e-mail — nous avons aussi exploité quelques fonctionnalités de :

- **Google** : tel que le service de stockage en ligne **Google Drive** pour le partage des différents documents, ainsi que la plateforme de messagerie instantanée et de visioconférence **Google Meet** pour planifier nos réunions.
- **Les réseaux sociaux** : en créant un groupe **WhatsApp** privé pour notre équipe.