



Projet : Analyse des données de Diagnostic
de Performance Énergétique (DPE)

Data Sciences Project

Master 1 : Data Sciences for Societal Challenges (DS4SC)

Encadré par :

Mme Veronika Peralta

M. Alexandre Chanson

1. Introduction

Le **Diagnostic de Performance Énergétique (DPE)** est un outil réglementaire central pour évaluer la consommation énergétique des bâtiments et leurs émissions de gaz à effet de serre, classées de A à G. Il est indispensable pour les transactions immobilières, l'accès aux aides à la rénovation et le suivi des politiques d'efficacité énergétique. Depuis 2020, l'**ADEME** publie une base de données open data regroupant plusieurs millions de diagnostics couvrant toutes les typologies de bâtiments et l'ensemble du territoire français. Cette base, riche et volumineuse, constitue une ressource stratégique pour analyser la performance énergétique du parc immobilier et soutenir les décisions en matière de rénovation.

Dans ce contexte, la problématique centrale du projet est de tirer parti de cette base de données volumineuse et hétérogène pour prédire la performance énergétique et environnementale des logements, compléter les informations manquantes et estimer les impacts financiers des rénovations, afin de fournir un outil décisionnel aux propriétaires et acteurs de la rénovation.

2. Formalisation des besoins

Pour répondre à la problématique, le projet se structure autour de quatre besoins opérationnels traduits en tâches de machine learning :

- 1. Prédire l'étiquette DPE pour identifier les logements les plus consommateurs d'énergie et anticiper leur performance énergétique.
- 2. Prédire l'étiquette GES pour identifier les bâtiments les plus émetteurs de gaz à effet de serre et cibler les rénovations à fort impact environnemental.
- 3. Reconstruire les recommandations de travaux manquantes pour compléter les DPE post-2021 et guider les décisions de rénovation.
- 4. Estimer le coût énergétique après travaux pour évaluer les gains financiers d'une rénovation et aider les propriétaires et décideurs à planifier leurs investissements.

Identification des variables cibles et descriptives

Besoin	Type de problème	Variable cible	Description de la cible
1	Classification supervisée multi-classes	etiquette_dpe	Classe énergétique du logement de A (très performant) à G (très énergivore)
2	Classification supervisée multi-classes	etiquette_ges	Classe d'émissions de gaz à effet de serre de A (faibles émissions) à G (très élevées)
3	Régression supervisée	cout_n_1	Coût énergétique annuel après rénovation (en €/an), basé sur anciens DPE (avant 2021)

4	Classification supervisée multi-classes	categorie_recommandation	7 catégories : Chauffage, Ventilation, Murs/Isolation, Toiture/Plafonds, Menuiserie/Fenêtres, Planchers/Sols, ECS Sanitaire
---	---	--------------------------	---

L'ensemble des variables explicatives utilisées pour les besoins est issu du jeu de données ADEME. Le tableau suivant présente leur description et leur type, ainsi que les besoins auxquels elles contribuent :

Nom de la variable	decennie_construction	etiquette_dpe	type_batiment	departement	qualite_isolation_enveloppe	type_energie_principale_chauffage	besoin_chauffage	type_energie_principale_ecs	besoin_ecs	cout_n	cout_n_1	classe_zone_climatique	siècle	besoin_refroidissement	Tranche_surface_habitable
Type	Ordinale	Catégorielle	Nominale	Catégorielle	Ordinal	Nominale	Numérique	Nominale	Nominale	Nominale	Nominale	Ordinale	Ordinale	Numérique	Numérique
Besoin	1,2,4	1,3,4	1,2,3,4	1	1,2,4	1,3,4	3,4	1,3,4	1,3,4	2	2	3,4	3	3	2,3,4

La sélection des variables explicatives pour chaque besoin repose à la fois sur une logique métier seules les caractéristiques du logement susceptibles d'influencer directement la variable cible considérée ont été retenues et sur les résultats de l'analyse exploratoire des données, qui ont permis de confirmer ou d'écarter certaines variables sur la base de leurs corrélations et associations statistiques avec les cibles

3. Analyse exploratoire des données

3.1. Statistiques descriptives

L'analyse des variables numériques continues révèle des distributions fortement asymétriques, caractéristiques des données énergétiques. Le tableau ci-dessous résume les principales statistiques descriptives calculées sur les 50 889 observations disponibles :

	Min	Q1	Médiane	Moyenne	Q3	Max	Écart-type	Effectif (n)
besoin chauffage	0.0	1759.8	3417.5	4930.997464	6681.5	19998.6	4352.325493	26889
besoin ecs	551.5	903.4	1067.6	1472.038477	1204.0	51434.1	3216.254325	26889
besoin refroidissement	0.0	0.0	0.0	369.889512	468.1	25422.1	1006.626756	26889
surface habitable	9.1	39.8	57.0	60.002038	75.0	425.2	29.315194	26889

Plusieurs observations s'imposent. Le besoin de chauffage présente un écart-type très élevé (4 352) par rapport à sa médiane (3 418), traduisant une forte hétérogénéité entre logements. Le besoin de refroidissement affiche une médiane nulle, ce qui indique que la majorité des logements du dataset ne sont pas concernés par la climatisation, seules les zones climatiques chaudes (H3 notamment) présentent des valeurs significatives. Le besoin en ECS, bien que plus stable, contient des valeurs extrêmes atteignant 51 434 kWh/an, suggérant la présence de valeurs aberrantes à traiter lors du pré-processing.

3.2. Corrélations et associations avec les variables cibles

L'analyse des relations entre les variables explicatives et l'étiquette DPE confirme la pertinence des variables retenues :

Classe DPE	Besoin chauffage	Besoin ECS	Besoin refroidissement	Énergie chauffage	Zone climatique	Type de bâtiment
DPE (A-G)	Corrélation positive $\rho \approx 0,47$	Corrélation faible $\rho \approx -0,11$	Corrélation négative $\rho \approx -0,36$	Association forte $\chi^2 = 2783, p < 0,001$	Association forte $\chi^2 = 4373, p < 0,001$	Association significative $\chi^2 = 494, p < 0,001$

Ces résultats confirment que toutes les variables retenues présentent des liens significatifs avec l'étiquette DPE. En particulier, le type d'énergie de chauffage et la zone climatique constituent les variables catégorielles les plus discriminantes, tandis que le besoin de chauffage est la variable numérique la plus corrélée à la cible.

3.3. Déséquilibre des classes des variables cibles

L'analyse des distributions des variables cibles révèle un déséquilibre notable qu'il conviendra de traiter lors de la phase de modélisation.

Pour la variable *categorie_recommandation*, la classe « Non renseigné » représente à elle seule 50,06 % des observations, suivie de « Chauffage » (14,53 %) et « Autres » (10,58 %), tandis que les catégories « Planchers/Sols » et « ECS Sanitaire » ne représentent respectivement que 0,77 % et 0,39 % des cas.

La distribution des classes de l'étiquette GES est déséquilibrée, avec une surreprésentation des classes C (28,75 %), B (23,96 %) et D (16,36 %), qui concentrent à elles trois près de 69 % des observations, contre une sous-représentation marquée des classes F (5,01 %) et G (2,17 %).

La distribution des classes de l'étiquette DPE est déséquilibrée .

4. Pré Processing et Feature Engineering

Séparation entraînement / test

Pour garantir une évaluation fiable, les données ont été divisées en ensembles d'entraînement (70 %) et de validation (30 %). Le prétraitement (ex. standardisation) est appris uniquement sur l'entraînement puis appliqué à la validation avec les mêmes paramètres afin d'éviter tout *data leakage*. Pour les besoins 1, 2 et 4, la séparation est **stratifiée** afin de conserver la distribution des classes et limiter les biais d'évaluation.

Imputation

Avant d'imputer les valeurs manquantes, nous avons identifié leur mécanisme (MCAR, MAR, MNAR) afin de choisir une méthode adaptée. L'hypothèse MCAR a été testée en comparant les observations avec et sans manquants (test *t* pour les variables numériques, Chi-deux pour les catégorielles) : des p-values > 0,05 suggèrent un MCAR. Une analyse complémentaire de type *Little* (tests multiples entre groupes) a permis d'orienter vers MAR lorsque la significativité globale était élevée. Enfin, le MAR a été confirmé en étudiant le lien entre l'indicateur de manquant et les autres variables (corrélations point-bisériale pour numériques, Cramér's V pour catégorielles, seuil 0,1). La plupart des manquants étant MAR, nous avons privilégié des imputations avancées (KNN, régression multiple et MICE) plutôt que des méthodes simples.

Exemple d'imputation :

Besoin	Variable descriptive	% NaN	Méthode	Justification
1	cout_n	26.1%	Régression Ridge	Variable MAR avec dépendances observées ; la régression Ridge a été retenue pour estimer les valeurs manquantes en tenant compte des corrélations entre prédicteurs.
2	besoin refroidissement	26.3%	Régression linéaire	Variable MAR avec forte corrélation ($r \approx 0,99$) avec la catégorie de recommandation ; la régression linéaire permet d'imputer les valeurs manquantes en exploitant cette relation, les prédictions sont clippées aux valeurs min/max observées pour respecter les contraintes physiques du domaine
3	annee_construction	~36%	MICE (Iterative imputer)	Les logements sans information sur l'année présentent des caractéristiques proches des autres, suggérant un mécanisme MCAR ou MAR faible. L'imputation est réalisée avec MICE , plus réaliste qu'une simple médiane, en combinant plusieurs variables explicatives. Les années imputées sont ensuite arrondies et bornées pour rester cohérentes.
4	besoin_chauffage & besoin_ecs	100%	Suppression	Variables non exploitables dans le dataset avant 2021 (valeur -1 constante).

Besoin 1: prédiction des étiquettes DPE, **Besoin 2:** prédiction des emission GES, **Besoin 3:** prédiction du coût énergétique après travaux: , **Besoin 4:** prédiction des catégories de recommandations de travaux

Normalization et standardisation

La normalisation garantit une contribution équitable des variables. Selon leur distribution, on applique soit une transformation (log/racine) pour réduire l’asymétrie, puis on vérifie visuellement l’amélioration, soit une standardisation pour les variables déjà symétriques(centrage-réduction).

Besoin	Variable descriptive	Distribution initiale	Méthode	Justification
1	count_n	fortement asymétrique à droite	standardisation par Z-score (StandardScaler)	Elle a été appliquée afin de recentrer la variable autour de 0 et de réduire l'effet des écarts d'échelle, ce qui est plus adapté que Min-Max dans ce contexte.
2	besoin chauffage	Asymétrie droite	PowerTransformer Yeo-Johnso	Cette transformation réduit l'impact des valeurs extrêmes et améliore la normalité de la variable, ce qui favorise une meilleure convergence des modèles et des prédictions plus fiables
3	besoin_refroidissement	Très asymétrique à droite (94 % de zéros, skewness ≈ 143)	Variable binaire (présence) + log sur valeurs positives + RobustScaler	Variable très asymétrique et zéro-inflée : on sépare présence et intensité, applique un log sur les valeurs positives, puis une normalisation robuste pour limiter l'effet des valeurs extrêmes.
4	annee_construction	Distribution concentrée entre 1950 et 2010	Suppression des valeurs hors bornes (1800–2021) + transformation en décennies	Regroupement métier permettant de réduire le bruit temporel et améliorer la robustesse du modèle.

Encoding

L'encodage convertit les variables catégorielles en valeurs numériques exploitables par les algorithmes. Le choix dépend du nombre de catégories : un one-hot encoding est privilégié pour un faible nombre de catégories (préservant leur indépendance), tandis qu'un encodage ordinal ou basé sur la fréquence est préféré pour limiter la dimensionnalité. Notre dataset comptant au maximum 11 catégories, le one-hot encoding a été appliqué à la majorité des variables.

Besoin	Variable descriptive	Méthode	Justification
1	configuration_installation_ecs	One-hot encoding	Les modalités correspondent à des systèmes distincts sans ordre naturel. Le One-Hot Encoding permet donc de les représenter sans introduire de hiérarchie artificielle.
2	zone_climatique	Ordinal encoding	La variable zone_climatique présente un ordre naturel (H1 < H2 < H3), allant du plus froid vers le plus chaud. L'Ordinal Encoding est donc approprié, car cette approche préserve l'information ordinale tout en réduisant la dimensionnalité par rapport au one-hot encoding.
4	type_batiment	One-hot encoding	Cette variable ne présente pas d'ordre strict exploitable par le modèle. le one-hot encoding permet de représenter chaque modalité indépendamment sans introduire de relation artificielle entre catégories, garantissant ainsi un traitement équitable par le modèle.

Équilibrage de classe

Besoin	Approche retenue	Justification
1	SMOTEsur l'ensemble d'entraînement	Rééquilibrage des classes minoritaires sans altérer validation et test
2	SMOTE	Distribution initiale déséquilibrée (C/B surreprésentées à 28%, F/G à 2%). SMOTE génère des exemples synthétiques et équilibre toutes les classes à 14,29%
4	Random Forest baseline	Les approches testées (SMOTE, class_weight, XGBoost) donnent des Macro F1 proches (≈0,28) ; le baseline est retenu pour préserver la distribution réelle des données

Feature selection

Afin de réduire la dimensionnalité, éliminer le bruit et améliorer la performance et l’interprétabilité des modèles, nous avons procédé à la sélection des variables pour chaque besoin de la manière suivante :

Besoin	Approche	Variables retenues
1	(1) Analyse de colinéarité (corrélation absolue > 0,95) : suppression de 7 variables redondantes. (2) VarianceThreshold : élimination de 2 variables quasi-constantes. (3) Random Forest + SelectFromModel : conservation des variables les plus importantes.	26
2	(1) VarianceThreshold (variance < 0,1) : suppression des features quasi-constantes. (2) Random Forest (Embedded) : évaluation de l'importance des variables sur 200 000 observations (accuracy = 0,8474). (3) Permutation importance (Wrapper) : mesure de la dégradation de l'accuracy lors de la permutation des valeurs sur l'échantillon test.	13
3	(1) Analyse de corrélation avec la variable cible : identification des variables les moins pertinentes. (2) Variance Inflation Factor (VIF) : détection et réduction de la colinéarité entre variables explicatives. (3) Random Forest : confirmation de la contribution prédictive des variables retenues.	11
4	(1) Sélection par pertinence métier : variables directement liées aux recommandations énergétiques. (2) Random Forest (Embedded) : validation par les importances, la décennie de construction est la variable la plus contributive (~40 %), suivie du type de bâtiment et des configurations techniques (chauffage, ECS).	5

5. Modélisation

5.1. Besoin 1 Prédiction étiquettes DPE

Methodology

The data were split into three subsets: a training set, a validation set, and a test set. The classes were numerically encoded using LabelEncoder. Stratified cross-validation (Stratified K-Fold, k=5) was used during hyperparameter tuning to evaluate the models reliably while preserving the class distribution in each fold. Hyperparameter tuning was carried out with RandomizedSearchCV to optimize model performance. The final model was then trained on the training data, tuned using the validation set, and finally evaluated on the test set.

Rationale for Model Selection

For the prediction of the DPE class, several supervised learning models were used to compare their performance on a classification task. The selected models include linear approaches (Logistic Regression), tree-based methods (Random Forest), and gradient boosting algorithms (XGBoost, LightGBM, and CatBoost), all of which are widely recognized for their effectiveness in classification problems. This range of models makes it possible to assess different modeling capabilities, including both linear and non-linear relationships, and to identify the most effective approach. An SVM model and a neural network (MLP) were also considered, but the latter could not be fully used because of computational time constraints.

Model Hyperparameters

The model hyperparameters were not selected arbitrarily. A hyperparameter search procedure based on cross-validation was implemented to identify the best configurations and improve each model’s generalization performance. Only the most comparable hyperparameters across models are reported in the table below; some algorithm-specific parameters are therefore not included.

Modèle	Max_depth	learning_rate	n_estimators	subsample	colsample_bytree	reg_lambda	reg_alpha	gamma
Logistic Regression	/	/	/	/	/	/	/	/

Random Forest	20	/	400	/	/	/	/	/
XGBoost	6	0.05	2000	0.9	0.8	2	0.01	0.3
LightGBM	15	0.1	500	0.8	0.8	2	0	/
CatBoost	10	0.1	1000	/	/	/	/	/

Evaluation Metrics

These metrics provide a complementary view of model performance by taking into account both overall accuracy and model behavior for each class.


Metric	Why
Accuracy	Measures the overall proportion of correct predictions.
F1-score macro	Gives equal weight to each class, which is relevant when the dataset is imbalanced.
Confusion matrix	Provides a detailed view of classification errors across the different classes.

Comparative Results Across Models



Model	Train accuracy	Validation accuracy	Test accuracy	Macro F1
Logistic Regression	0.5135	0.5151	0.3786	0.38
Random Forest	0.9900	0.9414	0.9366	0.93
XGBoost	0.9947	0.9485	0.9408	0.93
LightGBM	0.9758	0.9400	0.9317	0.92
CatBoost	0.9832	0.9447	0.9347	0.92

Analysis of the Best-Performing Model

Among the evaluated models, XGBoost achieved the best overall performance, with a test accuracy of 94.08% and a macro F1-score of 0.93. It was therefore selected as the final model.



The learning curves (accuracy and loss) show that the model converges well. The validation and test results remain close, which confirms good generalization ability. The confusion matrix highlights overall satisfactory classification performance, with most predictions lying on the diagonal. The observed errors mainly concern neighboring or similar classes.



Finally, the feature importance analysis shows that `surface_habitable`, `consommation_energie`, and `estimation_ges` are among the variables that contribute most to the model's decisions. These results confirm that XGBoost is the most effective model for this classification task.

Critical Analysis

Logistic regression produces the weakest results, indicating that this problem cannot be adequately captured by a purely linear model. In contrast, tree-based models better exploit the data structure, with XGBoost emerging as the top-performing method. This model delivers strong overall performance, reliable evaluation through stratified cross-validation, and good generalization, as validation and test scores are close. However, certain classes, particularly Class B, remain difficult to predict, with confusion occurring between neighboring classes, and the complexity of boosting models makes training longer and interpretation more challenging than simpler methods.

Business Interpretation

The selected model predicts the class with an accuracy of about 94%, which represents a strong level of performance. Although some neighboring classes are still occasionally difficult to distinguish, the model overall meets the classification objective and can be used as a decision-support tool.

5.2. Besoin 2 Prédiction des étiquettes GES

Méthodologie adoptée

Afin de répondre à ce besoin, une méthodologie en deux étapes a été mise en place. Elle repose d'abord sur un benchmark de modèles de machine learning, suivi de l'optimisation des hyperparamètres du modèle le plus performant, puis sur une comparaison avec des approches de deep learning. Cette démarche comparative et itérative vise à identifier les modèles les mieux adaptés aux données et à améliorer leur capacité de généralisation.

Benchmark des modèles de classification (Machine Learning)

Dans un premier temps, un benchmark d'algorithmes de classification supervisée a été réalisé afin de comparer leurs performances et d'identifier les plus adaptés à la prédiction des étiquettes GES. Les modèles testés couvrent plusieurs familles, incluant des modèles linéaires, des modèles basés sur des arbres et des méthodes d'ensemble, ainsi que des techniques de boosting.

Paramétrage des modèles

Les modèles ont été implémentés en utilisant leurs configurations par défaut, avec quelques ajustements des hyperparamètres principaux (notamment le nombre d'itérations ou d'arbres, ainsi que les fonctions objectives

pour les problèmes de classification multi-classes). Ces choix permettent d'assurer une base de comparaison homogène entre les différents algorithmes. Le tableau suivant présente les principaux paramètres utilisés pour chaque modèle.

Modèle	Paramètres principaux
LightGBM	objective='multiclass', num_class=7, random_state=42
CatBoost	iterations=500, random_state=42, verbose=0
Random Forest	n_estimators=200, random_state=42
Extra Trees	n_estimators=200, random_state=42
Gradient Boosting	n_estimators=200, random_state=42
HistGradientBoosting	random_state=42

Évaluation des performances des modèles

Chaque modèle est évalué à l'aide de deux métriques principales : **l'accuracy et le F1-score**, ce dernier étant privilégié en raison du déséquilibre des classes. Afin d'obtenir une estimation fiable et robuste des performances, une validation croisée de **5 folds** est utilisée, permettant de mieux apprécier la capacité de généralisation des modèles et de réduire les biais liés à une unique partition des données. Le tableau suivant présente les résultats obtenus pour chaque modèle.

Modèle	CV Acc Mean	CV Acc Std	Train Acc	Test Acc	Test F1
LightGBM	0.7994	0.0027	0.8205	0.8008	0.8012
HistGradientBoosting	0.8202	0.0018	0.8598	0.8238	0.8243
Gradient Boosting	0.8014	0.0031	0.8362	0.8056	0.8061
CatBoost	0.7831	0.0023	0.7955	0.7844	0.7848
Random Forest	0.7667	0.0024	0.8353	0.7694	0.7696

Extra Trees	0.6341	0.0026	0.6797	0.6311	0.6263
Logistic Regression	0.4465	0.0061	0.4410	0.4408	0.4239





Les résultats obtenus montrent une nette supériorité des modèles de boosting, capables de capturer des relations complexes et non linéaires dans les données. En particulier, le modèle **HistGradientBoosting** se distingue comme le plus performant, suivi de très près par **LightGBM**. Les modèles basés sur des arbres classiques, tels que **Random Forest** et **Extra Trees**, affichent des performances correctes mais moins robustes, tandis que la **régression logistique** se révèle peu adaptée au problème multi-classe et au déséquilibre des données, confirmant la nature non linéaire du problème. À l'issue de cette première étape, les deux meilleurs modèles retenus sont **HistGradientBoosting** et **LightGBM**.

Optimisation des hyperparamètres

Après avoir identifié les modèles les plus performants, une phase d'optimisation des hyperparamètres a été réalisée afin d'améliorer les performances prédictives, d'ajuster finement le comportement des modèles et de maximiser leur capacité de généralisation tout en limitant le surapprentissage.

Optimisation de HistGradientBoostingClassifier:


L'optimisation du modèle **HistGradientBoosting** a été réalisée avec **Optuna**, en explorant **30 combinaisons d'hyperparamètres** via une **validation croisée stratifiée 3-folds**, soit 90 entraînements au total, pour un temps de calcul d'environ 283 minutes. Optuna utilise un **algorithme bayésien (TPESampler)** et un pruner médian pour accélérer la recherche. L'analyse des graphiques montre une phase initiale d'exploration instable, suivie d'une stabilisation des scores autour de 0,83–0,836, confirmant la convergence vers des zones performantes. Les hyperparamètres les plus influents sont **min_samples_leaf** et **max_depth**, tandis que **l2_regularization** joue un rôle secondaire. Les meilleurs essais combinent un **max_iter** élevé (~550) avec un **learning_rate** faible (~0,06), illustrant le compromis classique entre nombre d'itérations et vitesse d'apprentissage.



Résultats de l'optimisation

Les **hyperparamètres optimaux retenus** sont: `max_iter = 550`, `max_depth = 25`, `learning_rate ≈ 0,064`, `min_samples_leaf = 50`, `l2_regularization = 2,6`, `max_bins = 255`, `max_leaf_nodes = 127` et `n_iter_no_change = 15`.

Le modèle final, ré-entraîné sur l'ensemble complet, atteint un score CV de 0,8361, une **accuracy de 84,49 %** sur le test, et des F1-scores pondéré et macro de 0,845 et 0,842, avec la Classe 0 la plus performante (F1 = 0,920) et les classes 5 et 6 les plus difficiles à discriminer. La qualité discriminante du modèle est confirmée par les courbes ROC multi-classes : toutes les classes affichent un AUC supérieur ou égal à 0,97, avec un AUC macro de 0,9819 et un AUC micro de 0,9831, traduisant une excellente capacité du modèle à distinguer chaque classe du reste, même pour les classes les plus délicates.



Optimisation LightGBM

L'optimisation du modèle LightGBM a été réalisée à l'aide d'Optuna, en suivant une approche similaire à celle adoptée pour HistGradientBoosting afin de garantir une comparaison cohérente entre les modèles. Une recherche bayésienne des hyperparamètres a été effectuée sur 30 essais, combinée à une validation croisée stratifiée en 2 folds, soit un total de 60 entraînements. Les hyperparamètres explorés incluent à la fois les paramètres principaux et ceux de régularisation, notamment **learning_rate**, **n_estimators**, **num_leaves** et **max_depth**, qui contrôlent la capacité d'apprentissage et la complexité du modèle. Les paramètres de régularisation (**reg_alpha**, **reg_lambda**, **min_split_gain**) permettent de limiter le surapprentissage, tandis que les paramètres de sous-échantillonnage (**subsample**, **colsample_bytree**) améliorent la robustesse.

Par ailleurs, deux types de boosting ont été explorés (**gbdt** et **dart**), ce dernier introduisant un mécanisme de dropout des arbres visant à renforcer la généralisation.


Résultats de l'optimisation

Le modèle LightGBM final utilise les hyperparamètres suivants : **n_estimators = 700**, **learning_rate = 0,03**, **num_leaves = 60**, **max_depth = 12**, **min_child_samples = 12**, **subsample = 0,9**,


colsample_bytree = 0,9, reg_alpha = 0,01 et reg_lambda = 0,05, ainsi qu'un **rééquilibrage des classes personnalisé** via *class_weight*, consistant à attribuer des poids plus élevés aux classes minoritaires (notamment F et G) afin d'améliorer leur prédiction dans un contexte déséquilibré. Les performances du modèle sont évaluées à l'aide d'une **validation croisée stratifiée à 5 folds**, qui consiste à diviser les données en 5 sous-ensembles en conservant la proportion des classes, puis à entraîner et tester le modèle sur différentes combinaisons afin d'obtenir une estimation fiable et robuste de ses performances

Analyse des résultats

Les résultats obtenus montrent que le modèle LightGBM présente de bonnes performances et une forte stabilité, avec un F1-score moyen en validation croisée de **0,8424** et un écart très faible entre les folds (std = 0,0012), ce qui indique une excellente robustesse et une bonne capacité de généralisation. La comparaison entre les performances sur les données d'entraînement (0,9024) et de validation (0,8422) met en évidence un léger surapprentissage (gap $\approx 0,06$), qui reste toutefois modéré et acceptable au regard de la complexité du modèle.




L'analyse des courbes de validation montre que l'augmentation du nombre d'arbres améliore les performances jusqu'à un optimum autour de 1000 itérations, confirmant que le modèle bénéficie d'un apprentissage progressif avec un faible learning rate. Globalement, ces résultats confirment que le modèle est bien calibré : il capture efficacement les relations dans les données tout en conservant une bonne capacité de généralisation, malgré la difficulté liée au déséquilibre des classes et à la proximité entre certaines catégories.



Par ailleurs, la **comparaison entre les courbes d'entraînement et de validation** illustre un écart limité, cohérent avec le léger surapprentissage observé, et témoigne d'un bon compromis entre biais et variance. L'**importance des variables** met en évidence le rôle prépondérant de certaines caractéristiques dans les prédictions, ce qui renforce la cohérence et l'interprétabilité du modèle.

En ce qui concerne la **matrice de confusion**, elle montre que la majorité des prédictions sont correctes, bien que certaines confusions persistent entre classes proches, notamment pour les classes minoritaires, ce qui est attendu dans un contexte déséquilibré. La **distribution des probabilités prédites** confirme que le modèle parvient globalement à discriminer les classes, malgré un léger chevauchement expliquant certaines erreurs.




Benchmark des modèles de Deep Learning, prédiction étiquettes GES

Dans un second temps, une approche de **deep learning** a été explorée via un benchmark de réseaux de neurones. Contrairement aux modèles classiques de machine learning, ces modèles sont entraînés avec une **séparation explicite entre jeu d'entraînement et jeu de validation**, sans validation croisée, afin de limiter le coût computationnel. Plusieurs configurations de **MLP (Multi-Layer Perceptron)** ont été testées, en faisant varier la **taille et la profondeur** du réseau, la **fonction d'activation** (ReLU, Tanh), le **niveau de régularisation** (alpha) et le **learning rate**. Au total, six architectures ont été évaluées, de réseaux de petite taille à des modèles plus profonds, et les performances ont été mesurées via l'**accuracy**, le **F1-score**, ainsi que par l'analyse du surapprentissage (écart entre performances sur train et test).

Configuration	Architecture (hidden layers)	Activation	Alpha (régularisation)	Batch size	Learning rate	Max iter	Early stopping
Config 1 – Small Network	(64, 32)	ReLU	0.0001	128	0.001	300	Oui
Config 2 – Medium Network	(128, 64, 32)	ReLU	0.0001	256	0.001	400	Oui
Config 3 – Large Network	(256, 128, 64, 32)	ReLU	0.0001	256	0.001	500	Oui
Config 4 – Régularisation forte	(128, 64, 32)	ReLU	0.001	256	0.001	400	Oui
Config 5 – Learning rate faible	(128, 64, 32)	ReLU	0.0001	128	0.0005	500	Oui
Config 6 – Activation Tanh	(128, 64, 32)	Tanh	0.0001	256	0.001	400	Oui

Configuration	Test Accuracy	Test F1-Score	Overfitting	Temps (s)	Itérations
Config 3 - Large Network	0.8334	0.8338	0.0359	882.0	111
Config 4 - Régularisation forte	0.8303	0.8305	0.0227	643.5	205
Config 5 - LR adaptatif	0.8272	0.8277	0.0280	994.6	269
Config 2 - Medium Network	0.8261	0.8266	0.0221	484.0	146
Config 6 - Tanh	0.8248	0.8251	0.0194	461.3	90
Config 1 - Small Network	0.8143	0.8146	0.0099	226.5	213

Analyse des résultats



L’analyse des résultats révèle que la **Config 3 (Large Network)** est la meilleure, avec un **F1-score de 0,8338** et un surapprentissage modéré (0,0359), comme l’illustrent les graphiques gauche et droite. À l’inverse, la **Config 1 (Small Network)** présente le F1-score le plus faible (0,8146) et un surapprentissage très faible (0,0099), montrant que les architectures trop simples limitent la capacité prédictive. La **Config 4 (forte régularisation)** constitue un compromis intéressant : elle atteint un F1-score proche du maximum (0,8305) tout en conservant un surapprentissage faible, démontrant l’efficacité de la régularisation pour limiter le surapprentissage sans sacrifier la performance. Au terme du benchmark, la configuration **Large Network** est retenue comme le modèle de deep learning le plus performant.



Analyse approfondie des résultat du modèle config 3

Courbe d’apprentissage : convergence rapide des pertes Train et Validation durant les 20 premières époques, montrant un apprentissage efficace des patterns dominants. Entre les époques 20-40, un léger surapprentissage apparaît (Train Loss ~0.45 vs Validation Loss ~0.51-0.52). Après l’époque 40, la Validation Loss stagne

(0.51–0.54), avec fluctuations limitées grâce à la régularisation et à l'early stopping (déclenché à l'époque 111, point optimal ~90). Le modèle généralise bien malgré la difficulté à discriminer les classes GES intermédiaires.

Matrice de confusion et rapport de classification : la majorité des prédictions sont correctes ; erreurs concentrées entre classes adjacentes (C↔D, D↔E), reflétant la similitude des logements intermédiaires. Classe A la mieux reconnue, classe G (sous-représentée) conserve une précision élevée (82,9 %). Légère sous-estimation des logements les plus polluants (biais conservatif acceptable).

Courbes ROC multi-classes : toutes les classes AUC ≥ 0,97 ; AUC macro = 0,9803, AUC micro = 0,9810, confirmant une excellente capacité discriminante pour chaque classe.



6. ÉVALUATION DÉTAILLÉE - MEILLEUR MODÈLE
=====

Classification Report:				
	precision	recall	f1-score	support
Classe 0	0.9288	0.8714	0.8992	10500
Classe 1	0.8604	0.8535	0.8570	10500
Classe 2	0.8105	0.8342	0.8222	10500
Classe 3	0.8232	0.8135	0.8184	10500
Classe 4	0.7926	0.8194	0.8058	10500
Classe 5	0.7963	0.8338	0.8146	10500
Classe 6	0.8290	0.7778	0.8026	4843
accuracy			0.8334	67843
macro avg	0.8344	0.8291	0.8314	67843
weighted avg	0.8349	0.8334	0.8338	67843

Business Interpretation

Les modèles développés permettent de prédire avec une bonne fiabilité (accuracy ≈ 84 %) les classes d'émissions de gaz à effet de serre des logements, constituant ainsi un outil pertinent pour l'aide à la décision. Ils permettent d'identifier rapidement les logements les plus polluants et de prioriser les actions de rénovation énergétique, d'anticiper l'impact environnemental des bâtiments même avec des données incomplètes, de soutenir les politiques publiques en ciblant les segments nécessitant des interventions prioritaires, et d'aider les propriétaires et investisseurs à évaluer les émissions et les risques associés. L'analyse des variables importantes montre que les émissions de GES sont fortement liées au type d'énergie utilisée, aux besoins énergétiques et aux caractéristiques thermiques du logement, des résultats cohérents avec la logique métier qui renforcent la crédibilité des deux modèles.

5.3 Besoin 3 Prédiction des coûts énergétiques

Methodology

La méthodologie adoptée pour ce besoin repose sur une démarche comparative. Après le preprocessing, l'encodage, les transformations et la sélection des variables, plusieurs modèles de régression ont été entraînés sur le même jeu de données préparé. L'objectif était de comparer une baseline simple à des modèles plus complexes capables de mieux capturer les relations non linéaires entre les variables explicatives et le coût énergétique. Les modèles testés sont les suivants : régression linéaire, Random Forest, Gradient Boosting, XGBoost et réseau de neurones profond. La comparaison a été réalisée à l'aide de métriques de régression adaptées, puis complétée par une analyse plus fine du modèle retenu.

Rationale for Model Selection

Le choix des modèles suit une logique progressive. La **régression linéaire** a été utilisée comme baseline afin d'établir un point de comparaison simple. Les modèles **Random Forest**, **Gradient Boosting** et **XGBoost** ont ensuite été retenus car ils sont bien adaptés aux données tabulaires et capables de modéliser des relations non linéaires. Enfin, un **réseau de neurones profond** a été testé afin d'explorer une architecture plus flexible, capable de capturer des relations complexes entre variables.

Dans cette étude, le réseau de neurones n'a pas été retenu uniquement pour sa performance brute, mais surtout pour sa **stabilité entre entraînement, validation et test**, ce qui traduit une meilleure capacité de généralisation et un risque plus faible d'overfitting. À l'inverse, le Random Forest obtient de très bonnes performances quantitatives, mais son comportement apparaît un peu moins homogène.

Model Hyperparameters

Les hyperparamètres principaux utilisés pour chaque modèle sont présentés dans le tableau ci-dessous.

Modèle	Hyperparamètres principaux
Régression linéaire	Paramètres par défaut
Random Forest	<code>n_estimators = 100</code> , <code>max_depth = 15</code> , <code>min_samples_split = 10</code> , <code>min_samples_leaf = 4</code> , <code>random_state = 42</code> , <code>n_jobs = -1</code>
Gradient Boosting	<code>n_estimators = 100</code> , <code>learning_rate = 0.05</code> , <code>max_depth = 3</code> , <code>random_state = 42</code>
XGBoost	Modèle entraîné dans la comparaison finale
Réseau de neurones profond	Architecture <code>128-64-32-16-1</code> , activation <code>ReLU</code> , régularisation <code>L2 = 0.001</code> , optimiseur <code>Adam</code> , <code>learning_rate = 0.001</code> , <code>epochs = 150</code> , <code>batch_size = 256</code> , <code>validation_split = 0.2</code> , <code>ReduceLROnPlateau</code>

Pour le réseau de neurones, l'architecture finale comprend quatre couches cachées suivies d'une couche de sortie. L'apprentissage a été effectué sur 150 époques avec un batch size de 256 et une validation interne de 20 %, ce qui a permis de suivre l'évolution conjointe des performances d'entraînement et de validation.

Evaluation Metrics

L'évaluation des modèles a été réalisée à l'aide de trois métriques de régression.

Métrique	Rôle	Interprétation
MAE	Mesure l'erreur absolue moyenne entre valeurs réelles et prédites	Plus elle est faible, meilleur est le modèle
RMSE	Mesure l'erreur quadratique moyenne en pénalisant davantage les grandes erreurs	Plus elle est faible, meilleur est le modèle
R²	Mesure la part de variance expliquée par le modèle	Plus il est proche de 1, meilleur est le modèle

La **MAE** a été particulièrement utile pour interpréter directement l'erreur moyenne du modèle dans l'unité réelle de la variable cible. Le **RMSE** complète cette analyse en donnant plus de poids aux erreurs importantes, tandis que le **R²** permet d'évaluer la qualité globale de l'ajustement.

Comparative Results Across Models

Modèle 1	MAE	RMSE	R²	Modèle 2	MAE	RMSE	R²
Random Forest	74.22	570.78	0.9815	Gradient Boosting	160.46	652.91	0.9758
XGBoost	156.52	830.92	0.9607	Régression linéaire	1045.74	2953.93	0.5036

Les résultats comparatifs obtenus sur le jeu de test sont les suivants :Ces résultats montrent une nette supériorité des modèles non linéaires sur la régression linéaire. Parmi eux, **Random Forest** obtient les meilleures performances brutes sur le jeu de test, avec la plus faible MAE et le meilleur coefficient de détermination. **Néanmoins, ces résultats restent partiellement biaisés par la présence d'overfitting**, observée à travers un écart entre la performance brute et la stabilité attendue en généralisation. En ce sens, ce modèle apparaît comme très performant, mais moins fiable que le réseau de neurones du point de vue de la robustesse.





Figure 1 – Comparaison entre les valeurs prédites et les valeurs réelles pour le modèle Random Forest.

Analysis of the Best-Performing Model

Modèle	MAE entraînement	MAE validation	MAE test	Interprétation
Réseau de neurones profond	105.59	105.44	103.16	Les valeurs sont très proches, ce qui traduit une bonne généralisation et un faible risque d'overfitting.

Même si le Random Forest est le meilleur en performance brute sur le test, l'analyse détaillée du **réseau de neurones profond** montre qu'il s'agit du modèle le plus stable. Les écarts très faibles entre les performances d'entraînement, de validation et de test indiquent que le réseau de neurones ne se contente pas d'apprendre le jeu d'entraînement, mais conserve un comportement cohérent sur des données non vues. Cela constitue un argument fort en faveur de sa robustesse. Petit détail : le MAE affiché pendant l'entraînement du réseau de neurones est calculé sur la variable cible après normalisation avec un RobustScaler. Il ne peut donc pas être directement comparé au MAE obtenu après retour à l'échelle d'origine. Cela explique pourquoi la courbe d'apprentissage affiche des valeurs proches de **0,11**, alors que le MAE reporté pour les jeux d'entraînement, de validation et de test est d'environ **105**.



Figures 3,4 – Comparaison entre les valeurs prédites et les valeurs réelles sur le jeu d'entraînement et de test pour le réseau de neurones profond.

Critical Analysis

L'analyse critique des résultats montre que deux lectures sont possibles.

D'un côté, le **Random Forest** est le modèle qui obtient les meilleures métriques sur le jeu de test. Il constitue donc le meilleur modèle si l'on considère uniquement la performance quantitative immédiate. D'un autre côté, le **réseau de neurones profond** présente une meilleure homogénéité entre entraînement, validation et test. Cette stabilité suggère une meilleure capacité de généralisation et un risque plus limité d'overfitting.

La validation croisée renforce cette analyse, puisque le Random Forest reste très performant mais présente des résultats légèrement moins homogènes que ceux observés pour le réseau de neurones entre les différentes phases d'apprentissage. Dans le cadre de cette étude, le choix final s'est donc appuyé non seulement sur les performances, mais aussi sur la robustesse du modèle.

Business Interpretation

D'un point de vue métier, les résultats montrent que le coût énergétique dépend principalement de variables directement liées à la consommation et aux caractéristiques thermiques du logement. L'analyse d'importance issue du Random Forest met notamment en avant consommation_energie, cout_n_1, surface_habitable, besoin_chauffage et deperdition_enveloppe comme variables majeures dans la prédiction.

Cette hiérarchie est cohérente avec la logique métier : un logement plus grand, plus énergivore, avec des besoins de chauffage importants ou une enveloppe moins performante, tend à générer un coût énergétique plus élevé. Ainsi, au-delà de la simple performance prédictive, les résultats confirment aussi la pertinence des variables sélectionnées pour modéliser ce besoin.

5.4 Besoin 4 Prédiction des recommandations de travaux

Limite importante

Le dataset utilisé est une version dérivée des données DPE initiales, dans lesquelles un même logement peut contenir plusieurs recommandations. Dans le dataset fournit, seule la catégorie majoritaire est conservée par logement, ce qui introduit un biais d'évaluation : certaines prédictions jugées incorrectes peuvent en réalité correspondre à des recommandations présentes dans les données d'origine. Ainsi, bien que le besoin métier puisse s'apparenter à un problème multi-label, la structure du dataset conduit ici à une **formulation en classification multiclasse**, adaptée au cadre de cette étude.

Méthodologie et métrique d'évaluation

Les données ont été séparées en trois ensembles : **train, validation, test**. Le modèle a été entraîné sur train, comparé sur validation, puis confirmé sur test. Une **validation croisée stratifiée en 5 folds** a aussi été appliquée au modèle.

Métrique	Utilité
Accuracy	mesure globale
Precision / Recall / F1-score	lecture détaillée par classe
Macro F1	métrique principale en contexte déséquilibré

Matrice de confusion	analyse des erreurs
----------------------	---------------------

Le **Macro F1-score** est la métrique principale, car le dataset est déséquilibré.

Six modèles ont été comparés (Random Forest baseline, Random Forest + SMOTE, XGBoost, CatBoost, Balanced Random Forest, Réseau de neurones). Les résultats issus des expérimentations finales sont résumés dans le tableau ci-dessous.

Modèle	Accuracy valid	Macro F1 valid	Accuracy test	Macro F1 test
Random Forest baseline	0.4339	0.3055	0.4320	0.3028
XGBoost	0.4347	0.3039	0.4327	0.3008
RF + SMOTE ciblé	0.4242	0.2933	0.4234	0.2953
Balanced Random Forest	0.2972	0.2762	0.2979	0.2756
CatBoost	0.2827	0.2614	0.2847	0.2616
Réseau de neurones	0.4268	0.2564	0.4251	0.2558

Le Random Forest baseline est le meilleur modèle avec le Macro F1 le plus élevé (0,3055 en validation, 0,3028 en test) et une accuracy stable (0,4339 et 0,4320), confirmant sa bonne généralisation, tandis que XGBoost, malgré une accuracy légèrement supérieure sur le test (0,4327), présente un Macro F1 inférieur (0,3008), le rendant moins pertinent dans ce contexte déséquilibré.

À l’opposé, le Balanced Random Forest et CatBoost affichent les pires performances avec une accuracy très faible (≈0,29 et 0,28) et les Macro F1 les plus bas, ne parvenant pas à exploiter la structure des données.

Un cas intéressant est le réseau de neurones, qui atteint une accuracy proche du meilleur modèle (0,4268 en validation) mais le Macro F1 le plus faible (0,2564), montrant qu’il prédit bien les classes majoritaires tout en échouant sur les minoritaires, illustrant l’importance du Macro F1 dans ce contexte.

Modèle retenu

Le Random Forest baseline est donc retenu avec les paramètres suivants comme meilleur compromis entre performance globale, équilibre inter-classes et stabilité.:

Élément	Prétraitement	Modèle	n_estimators	random_state	n_jobs
Valeur	One-Hot Encoding	RandomForestClassifier	300	42	-1

Résultats par classe sur le test

Classe	Murs / Isolation	Chauffage	Ventilation	Toiture / Plafonds	Menuiserie / Fenêtres	Planchers / Sols	Améliorations techniques	ECS Sanitaire
F1-score	0.49	0.48	0.44	0.34	0.29	0.19	0.17	0.01

Le modèle reconnaît surtout les classes majoritaires. Les classes rares, en particulier **ECS Sanitaire**, restent difficiles à prédire.

Interprétation de la matrice de confusion

	Améliorations techniques	Chauffage	ECS Sanitaire	Menuiserie / Fenêtres	Murs / Isolation	Planchers / Sols	Toiture / Plafonds	Ventilation
Améliorations techniques	216	304	0	3	1089	0	173	188
Chauffage	58	2990	4	19	1610	3	300	884
ECS Sanitaire	5	100	1	1	42	0	3	46
Menuiserie / Fenêtres	37	273	1	288	547	74	71	124
Murs / Isolation	167	919	2	78	3580	46	416	501
Planchers / Sols	29	90	0	24	251	80	68	43
Toiture / Plafonds	39	394	0	11	731	2	635	84
Ventilation	48	1572	0	121	932	33	168	1891

La matrice de confusion du Random Forest baseline montre plusieurs confusions récurrentes, notamment entre :

- **Chauffage et Murs / Isolation**
- **Ventilation et Murs / Isolation**
- **Toiture / Plafonds et Murs / Isolation**

Ces confusions sont cohérentes d’un point de vue métier. Un même logement peut cumuler plusieurs faiblesses énergétiques et donc relever de plusieurs recommandations proches. Par exemple, un logement mal isolé peut aussi présenter un besoin de travaux sur le chauffage ou la ventilation.

La formulation multiclass accentue ce phénomène : comme une seule catégorie finale est conservée par logement, certaines prédictions pertinentes peuvent être considérées comme des erreurs.

Interprétation métier

Le **Random Forest baseline** est retenu car il obtient le meilleur compromis final entre robustesse, stabilité et performance sur la métrique principale. Il constitue une première réponse exploitable au besoin, tout en montrant les limites liées à la formulation multiclass du problème.

- il identifie correctement les grandes familles de recommandations ;
- il donne une estimation cohérente des travaux probables ;
- il est stable entre validation et test.

Conclusion

Besoin	Tâche	Modèle retenu	Métrique principale	Résultat test
1	Prédiction étiquette DPE	XGBoost	Macro F1	0.93
2	Prédiction étiquette GES	HistGradientBoosting	Macro F1	0.842
3	Prédiction coût énergétique	Réseau de neurones profond	MAE / R²	MAE ≈ 103 / R² ≈ 0.98
4	Prédiction recommandation de travaux	Random Forest baseline	Macro F1	0.3028

Ce projet démontre qu'il est possible de construire des modèles prédictifs fiables à partir de la base ADEME. Trois besoins sur quatre atteignent des performances élevées : Macro F1 de 0,93 pour la prédiction DPE, 0,842

pour le GES, et un R^2 de 0,98 pour l'estimation du coût énergétique, des résultats directement exploitables comme outils d'aide à la décision pour les acteurs de la rénovation.