

Université de Tours

UFR Sciences et Techniques — Département d'Informatique

Master DS4SC — Data Science for Societal Challenges

Rapport de synthèse de projet

Dashboard de Prédiction des AVC :

Analyse, nettoyage et visualisation de données cliniques

Encadrant : Fiona Calonne

Année universitaire : 2025-2026

Établissement : Département d'Informatique — 3 place Jean Jaurès — 41000 Blois

1. Contexte et objectifs du projet

Les accidents vasculaires cérébraux (AVC) représentent la deuxième cause de mortalité mondiale selon l'OMS, responsables de 11 % des décès. Malgré ce constat, 80 % des AVC sont évitables si les facteurs de risque sont identifiés suffisamment tôt. Ce projet s'inscrit dans une démarche de data science appliquée à la santé publique, avec pour objectif de transformer des données cliniques brutes en un outil d'aide à la décision destiné au personnel médical.

L'objectif principal était de construire un pipeline complet de traitement de données, depuis l'exploration brute jusqu'à la conception d'un tableau de bord interactif. Ce tableau de bord permet au personnel soignant d'identifier rapidement les profils de patients à risque élevé et de prioriser les interventions préventives.

1.1 Dataset utilisé

Le dataset retenu est le Stroke Prediction Dataset disponible sur la plateforme Kaggle (auteur : fedesoriano), sous licence open data. Il regroupe des données cliniques et socio-démographiques de 5 110 patients avec les caractéristiques suivantes :

- 5 110 observations, 12 variables d'entrée, 1 variable cible (stroke : 0 = pas d'AVC, 1 = AVC)
- Variables : âge, genre, hypertension, maladie cardiaque, statut marital, type de travail, type de résidence, taux de glucose, IMC, statut tabagique
- Déséquilibre de classes important : 4 861 patients sans AVC (95,1 %) contre 249 avec AVC (4,9 %)
- Valeurs manquantes : 201 valeurs absentes sur la colonne BMI, soit 3,9 % du dataset

1.2 Organisation du projet

Le projet s'est déroulé sur quatre semaines selon le planning suivant :

Semaine	Intitulé	Contenu principal
Semaine 1	Exploration & Profiling	Statistiques descriptives, rapport ydata-profiling, analyse des NaN et distributions
Semaine 2	Nettoyage & Préparation	Imputation, outliers, encodage, normalisation, feature engineering
Semaine 3	Machine Learning	SMOTE, entraînement de 5 modèles, évaluation, courbes ROC, diagnostic overfitting
Semaine 4	Dashboard	Google Looker Studio, 2 pages, 7 graphiques, filtres interactifs, partage

2. Missions réalisées

2.1 Phase 1 — Exploration et profiling des données

La première phase avait pour objectif d'établir un diagnostic complet du dataset avant toute transformation. Les outils Python utilisés (pandas, numpy, ydata-profiling) ont permis de produire un rapport automatisé révélant les éléments suivants :

- 201 valeurs manquantes sur la colonne bmi (3,9 % du dataset)
- Distribution asymétrique à droite (skewed right) sur avg_glucose_level et bmi
- Déséquilibre majeur : 4 861 patients sans AVC contre 249 avec AVC
- Une modalité non représentative dans la variable gender : la valeur « Other » (1 seul patient)
- Corrélations significatives entre l'âge, le taux de glucose, l'hypertension et la survenue d'un AVC

2.2 Phase 2 — Nettoyage et préparation des données

Le pipeline de nettoyage a été développé sur Google Colab en Python et a compris les étapes suivantes :

- Suppression de la colonne id (identifiant non informatif) et vérification des doublons
- Suppression de la modalité gender = « Other » (effectif insuffisant pour être représentatif)
- Imputation des valeurs manquantes du BMI par la méthode MICE
- Traitement des valeurs aberrantes par écrêtage IQR (méthode Winsorizing) sur glucose et BMI
- Feature engineering : création de tranches d'âge, classes IMC selon la classification OMS, classes de glucose (normal, pré-diabète, diabète, diabète sévère)
- Encodage des variables catégorielles : Label Encoding pour les variables binaires, One-Hot Encoding pour work_type et smoking_status
- Normalisation Min-Max des variables numériques continues (âge, glucose, BMI)

Bilan du nettoyage : 5 110 lignes / 12 colonnes / 201 NaN → 5 109 lignes / 17 colonnes / 0 NaN

2.3 Phase 3 — Modélisation Machine Learning

Cinq algorithmes de classification binaire ont été entraînés et comparés. Avant l'entraînement, le déséquilibre de classes a été corrigé par la technique SMOTE (Synthetic Minority Over-sampling TEchnique), qui génère des exemples synthétiques de la classe minoritaire pour atteindre un ratio 50/50 sur les données d'entraînement.

Modèle	Accuracy	Recall	F1-Score	AUC-ROC
Régression Logistique *	73,3 %	84,0 %	23,5 %	0,8377
Random Forest	79,0 %	52,0 %	20,0 %	0,766
XGBoost	83,0 %	42,0 %	19,0 %	0,770
MLP sklearn	85,0 %	34,0 %	18,0 %	0,738
MLP Keras	86,0 %	34,0 %	19,0 %	0,660

* **Modèle retenu :** Régression Logistique avec seuil de décision ajusté à 0,71. Ce modèle présente le meilleur AUC-ROC (0,8377) et détecte 72 % des vrais cas d'AVC sur le jeu de test (36 patients sur 50 correctement identifiés). Le seuil de 0,71 a été choisi selon un critère médical : maximiser le Recall (détection des AVC réels) plutôt que le F1-Score pur, car en contexte médical il est préférable de déclencher une fausse alarme plutôt que de manquer un AVC.

3. Réalisation — Dashboard interactif

La phase finale a consisté en la conception et le déploiement d'un tableau de bord interactif sur Google Looker Studio, à destination du personnel soignant et des décideurs hospitaliers. Le dashboard est structuré en deux pages complémentaires.

3.1 Architecture du dashboard

Page 1 — Vue d'ensemble : quatre cartes KPI (total patients, cas AVC, taux d'AVC, score AUC), graphique des taux d'AVC par tranche d'âge, graphique en anneau des niveaux de risque prédits, comparaison du glucose moyen entre patients AVC et non-AVC, taux d'AVC par type de travail.

Page 2 — Analyse détaillée : quatre filtres interactifs (niveau de risque, tranche d'âge, genre, tabagisme), graphique des taux d'AVC par facteur de risque (26 groupes), comparaison des performances des 5 modèles, tableau interactif des 5 109 patients trié par probabilité d'AVC décroissante.

3.2 Sources de données

Le dashboard s'appuie sur sept fichiers CSV distincts générés depuis le pipeline Python :

- dashboard_patients_FINAL.csv — 5 109 patients avec toutes les variables lisibles + probabilité d'AVC + niveau de risque prédits par le modèle
- dashboard_kpi.csv — Neuf indicateurs globaux (KPIs)
- dashboard_stats_age.csv — Taux d'AVC réel par tranche d'âge
- dashboard_facteurs_risque.csv — Taux d'AVC par facteur (26 groupes : hypertension, tabac, IMC, glucose, etc.)
- dashboard_stats_travail.csv — Taux d'AVC par type d'activité professionnelle
- dashboard_distributions.csv — Statistiques descriptives (médiane, moyenne, quartiles) du glucose comparées entre patients avec et sans AVC
- dashboard_performances_modeles.csv — Comparaison AUC / Recall / F1 des 5 modèles

4. Résultats et apports pour le personnel médical

4.1 Principaux résultats

Le modèle de Régression Logistique retenu présente un AUC-ROC de 0,8377, ce qui signifie qu'il est capable de distinguer correctement un patient AVC d'un patient non-AVC dans 84 % des cas. Avec un seuil de décision de 0,71, le modèle détecte 72 % des AVC réels (36 patients sur 50 dans le jeu de test), au prix d'un taux de fausses alertes élevé. Ce compromis est délibéré : en médecine préventive, il vaut mieux alerter inutilement que manquer un AVC réel.

Les facteurs de risque les plus fortement associés à la survenue d'un AVC dans ce dataset sont :

Facteur de risque	Taux d'AVC observé dans le groupe
Avec maladie cardiaque	17,0 %
61 ans et plus	16,0 %
Avec hypertension	13,3 %

Diabète sévère (glucose > 200)	12,9 %
Surpoids (IMC 25–30)	7,1 %
Ancien fumeur	7,9 %

4.2 Apport pour le personnel soignant

Le tableau de bord permet au personnel médical d'identifier en temps réel les patients les plus à risque au sein d'une cohorte. Grâce aux filtres interactifs, un médecin peut sélectionner un sous-groupe spécifique (par exemple : patients de 61 ans et plus avec hypertension) et visualiser instantanément les profils correspondants triés par probabilité d'AVC décroissante. Cet outil facilite la priorisation des consultations préventives sans nécessiter de compétences en data science.

5. Bilan — Compétences acquises et renforcées

5.1 Nouvelle compétence acquise : Google Looker Studio

Google Looker Studio était un outil entièrement nouveau pour moi avant ce projet. J'ai appris à connecter plusieurs sources de données Google Sheets à un même rapport, à construire un tableau de bord multi-pages avec différents types de graphiques (Bar chart, Donut chart, Scorecard, Table), à configurer des filtres interactifs applicables à l'ensemble des visualisations, et à partager et exporter le rapport.

5.2 Compétences renforcées

Modèles de Machine Learning. Ce projet a consolidé ma maîtrise de plusieurs algorithmes de classification en situation réelle. J'ai notamment approfondi le diagnostic d'overfitting par comparaison des performances train/test sur des distributions identiques, l'optimisation du seuil de décision selon un critère métier (ici médical), l'impact du déséquilibre de classes et les techniques de rééchantillonnage (SMOTE), ainsi que la comparaison rigoureuse des modèles par validation croisée stratifiée à 5 folds.

KNIME. L'exploration initiale des données sous KNIME a renforcé ma compréhension visuelle du pipeline de nettoyage. La correspondance directe entre chaque nœud KNIME et son équivalent Python (Statistics → `describe()`, Missing Value → `fillna()`, Numeric Outliers → IQR clipping, One to Many → `get_dummies()`) a facilité la structuration et la documentation du code.

5.3 Stack technique utilisée

Phase	Outils et bibliothèques
Exploration & Nettoyage	Python, pandas, numpy, ydata-profiling, scikit-learn, Google Colab
Machine Learning	scikit-learn, imbalanced-learn (SMOTE), XGBoost, TensorFlow / Keras
Visualisation Python	matplotlib, seaborn, plotly
Dashboard	Google Looker Studio, Google Sheets